Einführung in das Maschinelle Lernen

Vorlesung 4: Regularisierung und Überanpassung

Prof. Dr. Andreas Weber - Wintersemester 2026/27

1. Das Problem der Überanpassung

Ein Modell ist überangepasst (englisch: overfitting), wenn es die Trainingsdaten sehr gut abbildet, auf neuen Daten jedoch schlecht abschneidet. Das Modell hat dann nicht die zugrundeliegende Struktur gelernt, sondern das Rauschen der Trainingsmenge auswendig gelernt.

Typische Anzeichen sind ein sehr geringer Trainingsfehler bei gleichzeitig hohem Validierungsfehler. Die Differenz zwischen beiden nennt man die Generalisierungslücke.

2. Der Bias-Varianz-Kompromiss

Der erwartete Fehler eines Modells lässt sich zerlegen in:

  Gesamtfehler = Verzerrung^2 + Varianz + irreduzibles Rauschen

Ein zu einfaches Modell hat eine hohe Verzerrung (Unteranpassung), ein zu komplexes Modell eine hohe Varianz (Überanpassung). Ziel ist es, die Summe beider Terme zu minimieren.

3. Regularisierungsverfahren

L2-Regularisierung (Ridge)
Addiert die quadrierte Summe der Gewichte zur Verlustfunktion. Dies bestraft große Gewichte und führt zu glatteren Modellen. Der Hyperparameter Lambda steuert die Stärke der Bestrafung.

L1-Regularisierung (Lasso)
Addiert die Summe der Betragswerte der Gewichte. Im Unterschied zur L2-Regularisierung werden hier einzelne Gewichte exakt auf null gesetzt, wodurch eine automatische Merkmalsauswahl stattfindet.

Dropout
Während des Trainings werden zufällig ausgewählte Neuronen deaktiviert, üblicherweise mit einer Wahrscheinlichkeit zwischen 0,2 und 0,5. Dadurch kann sich das Netz nicht auf einzelne Neuronen verlassen. Beim Testen ist Dropout abgeschaltet.

Frühes Abbrechen (Early Stopping)
Das Training wird beendet, sobald der Validierungsfehler über mehrere Epochen hinweg nicht mehr sinkt. Die Anzahl der Epochen, die abgewartet wird, heißt Geduld (patience).

4. Prüfungsrelevante Hinweise

Die Herleitung der Bias-Varianz-Zerlegung ist klausurrelevant.
Übungsblatt 4 ist bis zum 15. Dezember 2026 abzugeben.